Методические указания по лабораторной работе (2 часть) «Виртуальная файловая система /proc»

1. Виртуальная файловая система /proc

Папки (каталоги, англ. directory) и файлы виртуальной файловой системы /ргос не хранятся на диске. Они создаются динамически при обращении к ним. Linux предоставляет ядру и модулям ядра дополнительный механизм передачи информации заинтересованным в ней процессам - это файловая система /ргос. Первоначально она создавалась с целью получения сведений о процессах (отсюда такое название). Теперь она интенсивно используется и самим ядром, которому есть что сообщить! Например, /ргос/modules -- список загруженных модулей, /ргос/meminfo -- статистика использования памяти.

Файловая система /proc фактически представляет собой интерфейс ядра, который позволяет получать информацию о процессах и ресурсах, которые они используют. При этом используется стандартный интерфейс файловой системы и системных вызовов. Из этого следует, что управление доступом к адресному пространству осуществляется при помощи обычных прав доступа — на чтение, на запись и выполнение. Общее взаимодействие с ргос заключается в использовании сат и есно из оболочки — командной строки. Например:

- 1 # cat / proc / cpuinfo
- 2 # echo " 50 " > /proc/sys/kernel / sched_rr_timeslice_ms

Данные о каждом процессе хранятся в поддиректории с именем, которым является идентификатор процесса: /proc/<PID>. В поддиректории процесса находятся файлы и поддиректории, содержащие данные о процессе (табл.1):

Таблица – файлы и поддиректории /proc/ <pid< th=""></pid<>
--

Элемент	Тип	Содержание		
cmdline	файл	Указывает на директорию		
		процесса		
cwd	символическая	Указывает на директорию		
	ссылка	процесса		
environ	файл	Список окружения процесса		
exe	символическая	Указывает на образ процесса (на		
	ссылка	его файл)		
fd	директория	Ссылки на файлы, которые		
		«открыл» процесс		

roo	ot	символическая	Указывает на корень файловой	
		ссылка	системы процесса	
sta	ıt	файл	Информация о процессе	

Процесс может получить свой идентификатор с помощью функции getpid().

Другой способ – использовать ссылку self: /proc/self.

2. Загружаемые модули ядра и виртуальная файловая система /proc

Файлы и поддиректории файловой системы /proc могут создаваться, их можно регистрировать и прекращать их регистрацию. Поэтому /proc часто используются загружаемыми модулями ядра. Файлы и поддиректории файловой системы /proc используют структуру proc_dir_entry:

```
struct proc_dir_entry {
  const char *name;
                       // имя виртуального файла
  mode_t mode;
                        // режим доступа
  uid tuid;
                  // уникальный номер пользователя -
                          // владельца файла
  uid_t uid;
                   // уникальный номер группы, которой
                          // принадлежит файл
  struct inode_operations *proc iops; // функции-обработчики операций с inode
  struct file_operations *proc_fops; // функции-обработчики операций с
файлом
  struct proc_dir_entry *next, *parent, *subdir;
  read_proc_t *read_proc; // функция чтения из /proc
  write_proc_t *write_proc;
                            // функция записи в /proc
  void *data:
                   // Указатель на локальные данные
```

```
atomic_t count; // счетчик ссылок на файл
};
 proc_dir_entry (9) ( Linux man: Ядро )
     struct proc dir entry {
         unsigned short low ino;
         unsigned short namelen;
         const char *name;
         mode_t mode;
         nlink_t nlink;
         uid_t uid;
         gid_t gid;
         unsigned long size;
         struct inode_operations *proc_iops;
         struct file_operations *proc_fops;
         struct proc_dir_entry *next, *parent, *subdir;
         void *data:
     . . . . .
     };
ow_ino: номер inode для директории. Для proc_register этот номер должен быть
уникальным в файловой системе /proc, значения определены в linux/proc fs.h>.
Для proc_register_dynamic номер inode назначаются динамически.
namelen: длина имени
name: уникальное имя виртуального файла (имя данного узла).
mode: тип и права доступа к узлу.
The node's type and permissions. Взяты из linux/stat.h>.
nlink: число линков к узлу. Инициализировать до 2, если режим включает
S IFDIR, 1 в противном случае.
uid: идентификатор пользователя (uid), которому принадлежит файл (узел),
обычно 0.
gid: идентификатор группы (gid), которой принадлежит узел, обычно 0.
size: устанавливает размер узла, значение будет отображаться как размер inode
в списках и будет возвращено stat. Если размер не нужен, то его устанавливают
равным нулю.
ops: определяет набор операций inode для узла / proc. Для узла каталога, если
нет особых требований, используются & proc dir inode operations. Для листового
узла, если нет специальных требований, устанавливается значение NULL.
data: непрозрачный указатель, который может использоваться обработчиками
ргос для передачи локальных данных. Допускается устанавливать свободно при
вызове proc register, обычно NULL. Этот указатель копируется в поле
inode.de_generic inode (by proc_get_inode), поэтому он доступен для всех процедур
proc, которые передаются inode.
```

3. Файловая система /proc: создание файлов, доступных для чтения

Методика работы с файловой системой /proc очень похожа на работу драйверов с файлами устройств: создаётся структура со всей необходимой информацией, включая указатели на функции-обработчики (в нашем случае имеется только один обработчик, который обслуживает чтение файла в /proc). Функция init_module() регистрирует структуру, а module_exit() отменяет регистрацию (см. лабораторную работу «Загружаемые модули ядра»).

Основная причина, по которой используется proc_register_dynamic состоит в том, что номер inode, для создаваемого файла, заранее неизвестен, поэтому ядро может определить его самостоятельно, чтобы предотвратить возможные конфликты. В обычных файловых системах, размещенных на диске, не в памяти, как /proc, inode указывает на то место в дисковом пространстве, где размещена индексная запись (index node, сокращенно -- inode) о файле. Inode содержит все необходимые сведения о файле, например права доступа, указатель на первый блок с содержимым файла.

Начиная с ядра 3.10 больше не поддерживается функция create_proc_entry(). Вместо нее используются функции:

```
#include #incl
```

```
/*
 * This is not completely implemented yet. The idea is to
 * create an in-memory tree (like the actual /proc filesystem
 * tree) of these proc_dir_entries, so that we can dynamically
 * add new files to /proc.
```

```
* parent/subdir are used for the directory structure (every /proc file has a
 * parent, but "subdir" is empty for all non-directory entries).
 * subdir_node is used to build the rb tree "subdir" of the parent.
struct proc_dir_entry
         * number of callers into module in progress;
         * negative -> it's going away RSN
        atomic_t in_use;
        refcount_t refcnt;
        struct <u>list_head pde_openers</u>; /* who did ->open, but not ->release */
        /* protects ->pde_openers and all struct pde_opener instances */
        spinlock_t pde_unload_lock;
        struct completion *pde_unload_completion;
        const struct inode_operations *proc_iops;
        union {
                const struct proc_ops *proc_ops;
                const struct file_operations *proc_dir_ops;
        };
        const struct dentry_operations *proc_dops;
        union {
                const struct seq_operations *seq_ops;
                 int (*single_show) (struct seq_file *, void *);
        };
        proc_write_t write;
        void *data;
        unsigned int state_size;
        unsigned int low_ino;
        nlink_t nlink;
        kuid_t uid;
        kgid_t gid;
        loff_t size;
        struct proc_dir_entry *parent;
        struct rb_root subdir;
        struct rb_node subdir_node;
        char *name;
        umode t mode;
        u8 flags;
        u8 namelen;
        char inline name[];
} __randomize_layout;
#include linux/compiler.h>
#include linux/types.h>
#include linux/fs.h>
struct proc_dir_entry;
struct seq_file;
```

```
struct seq_operations;
typedef int (*proc_write_t) (struct file *, char *, size_t);
extern void proc_root_init(void);
extern void proc_flush_pid(struct pid *);
extern struct proc_dir_entry *proc_symlink(const char *,
                struct proc_dir_entry *, const char *);
struct proc_dir_entry *_proc_mkdir(const char *, umode_t, struct proc_dir_entry *,
void *. bool);
extern struct proc_dir_entry *proc_mkdir(const char *, struct proc_dir_entry *);
extern struct proc_dir_entry *proc_mkdir_data(const char *, umode_t,
                                                struct proc_dir_entry *, void *);
struct proc_ops {
        unsigned int proc_flags;
                 (*proc_open) (struct inode *, struct file *);
        ssize_t (*proc_read) (struct file *, char __user *, size_t, loff_t *);
        ssize_t (*proc_read_iter) (struct kiocb *, struct iov_iter *);
        ssize_t (*proc_write) (struct file *, const char __user *, size_t, loff_t *);
        /* mandatory unless nonseekable_open() or equivalent is used */
        loff_t (*proc_lseek) (struct file *, loff_t, int);
                 (*proc_release) (struct inode *, struct file *);
        int
        __poll_t (*proc_poll) (struct file *, struct poll_table_struct *);
                 (*proc_ioctl) (struct file *, unsigned int, unsigned long);
        long
#ifdef CONFIG_COMPAT
        long
                 (*proc_compat_ioctl) (struct file *, unsigned int, unsigned long);
#endif
                 (*proc_mmap) (struct file *, struct vm_area_struct *);
        int
        unsigned long (*proc_get_unmapped_area) (struct file *, unsigned long,
unsigned long, unsigned long, unsigned long);
} __randomize_layout;
```

В то время как отдельные элементы proc_dir_entry должны были быть инициализированы в некоторых более ранних версиях ядра, разработчики, работающие с более новой версией ядра, используют структуру, которая хорошо знакома из разработки драйверов, struct file_operations, чтобы назначить методы доступа: open(), read(), write().

Структура file_operations используется для определения обратных вызовов (call back) чтения и записи.

Рассмотрим пример, который отображает текущее значение jiffies (счетчик тиков) всякий раз, когда он меняется.

Рассмотрим загружаемый модуль, в котором создается файл в файловой системе /proc:

```
2 #include linux/moduleparam.h>
3 #include ux/init.h>
4 #include 4 #include kernel.h>
5 #include linux/proc_fs.h>
6 #include <asm/uaccess.h>
7 #define BUFSIZE 100
8
9
10 MODULE_LICENSE("Dual BSD/GPL");
11 MODULE_AUTHOR( "Liran B.H");
12
13
14 static struct proc_dir_entry * ent;
16 static ssize_t mywrite(struct file *file, const char __user *ubuf,size_t count, loff_t *ppos)
17 {
         printk( KERN_ DEBUG "write handler\n");
18
19
         return - 1;
20 }
21
22 static ssize_t myread(struct file *file, char __user *ubuf,size_t count, loff_t *ppos)
23 {
24
          printk( KERN_ DEBUG "read handler\n");
25
         return 0;
26 }
27
28 static struct file_operations myops =
29 {
          .owner = THIS_MODULE,
30
31
          .read = myread,
32
         .write = mywrite,
33 };
34
35 static int simple_init(void)
36 {
37
         ent= proc_create("mydev", 0660, NULL, & myops);
38
         return 0;
39 }
40
41 static void simple_cleanup( void)
42 {
43
         proc_remove(ent);
44 }
45
46 module init(simple init);
47 module_exit(simple_cleanup);
```

Если откомпилировать и загрузить этот модуль, то будет создан новый файл /proc/mydev.

Можно протестировать функции read и write, используя cat и echo путем просмотра kernel log messages.

```
1 # echo "test" > /proc/mydev
2 bash: echo: write error: Operation not permitted
3
4 # cat /proc/mydev
5 # dmesg | tail -2
6 [ 694.640306] write handler
7 [ 714.661465] read handler
```

Родительский аргумент может быть NULL для корня /proc root или нескольких других значений, в зависимости от того, где нужно разместить файл. В таблице 2 перечислены некоторые другие родительские proc_dir_entrys, которые можно использовать, а также их расположение в файловой системе.

Table 2. Shortcut переменных proc_dir_entry

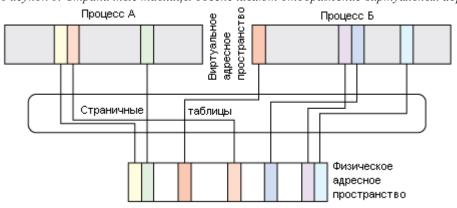
proc_dir_entry	Filesystem location	
proc_root_fs	/proc	
proc_net	/proc/net	
proc_bus	/proc/bus	
proc_root_driver	/proc/driver	

Можно также создавать каталоги в файловой системе /proc, используя proc_mkdir(), а также символические ссылки с proc_symlink(). Для простых /proc-записей, для которых требуется только функция чтения, используется create_proc_read_entry(), которая создает запись /proc и инициализирует функцию read_proc в одном вызове. Прототипы этих функций:

Передача данных из режима пользователя в режим ядра и из режима ядра в режим пользователя

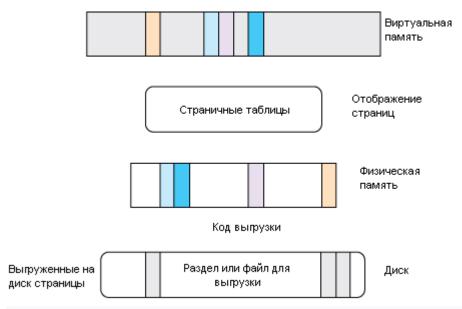
Поскольку адресные пространства процессов являются виртуальными, в системе их может быть много. Фактически само ядро и каждый из процессов располагаются в своих собственных изолированных адресных пространствах. Эти адресные пространства состоят из адресов виртуальной памяти, что позволяет нескольким процессам с независимыми адресными пространствами обращаться к физическому адресному пространству (т. е. к памяти, физически установленной на устройстве), имеющему значительно меньший объем. Такой подход обеспечивает не только удобство, но и безопасность, поскольку все адресные пространства являются независимыми и изолированными друг от друга.

Однако такая безопасность не дается даром. Поскольку ядро и каждый из процессов могут иметь одинаковые адреса, ссылающиеся на различные области физической памяти, при использовании общей памяти могут возникать задержки. К счастью, существует несколько решений этой проблемы. Совместное использование памяти пользовательскими процессами может обеспечиваться с помощью POSIX-механизма совместно используемой памяти shmem (shared memory mechanism), причем процессы могут иметь различные виртуальные адреса, ссылающиеся на одну и ту же область физической памяти. Отображение виртуальной памяти на физическую осуществляется через аппаратно реализованные страничные таблицы (рисунок 1). Аппаратная часть непосредственно выполняет отображение, а ядро управляет таблицами и их конфигурацией. Обратите внимание на то, что процесс может иметь большое, но не непрерывное, а «разбросанное» адресное пространство (как показано на рисунке); это означает, что небольшие области (страницы) адресного пространства отображаются на физическую память через таблицы страниц. Это позволяет процессу иметь большое виртуальное адресное пространство, но в физической памяти будут находиться только те страницы, с которыми процессор работает в текущий момент. Рисунок 1. Страничные таблицы обеспечивают отображение виртуальных адресов на физические



Поскольку память может выделяться процессам только тогда, когда это необходимо (по запросу), объем используемой виртуальной памяти может быть больше, чем объем имеющейся в системе физической памяти. В процессе замещения страниц (paging), который в Linux называется подкачкой (swap), наиболее редко используемые страницы перемещаются на более медленное устройство хранения (например, на жесткий диск), что позволяет обеспечить доступ к страницам, с которыми необходимо работать в данный момент (рисунок 2). Данный подход позволяет размещать в ОЗУ наиболее часто используемые страницы, а наиболее редко используемые выгружать на жесткий диск. Таким образом, обеспечивается более эффективное использование физической памяти. Заметьте, что некоторые страницы могут ссылаться на файлы — в этом случае грязные (dirty) страницы могут быть вытеснены (replacement) на диск, а чистые (по edit) страницы быть просто помеченными как свободные (копирование на диск не выполняется).

Рисунок 2. Подкачка позволяет эффективнее использовать физическую память, перемещая редко используемые страницы на более медленные и дешевые устройства

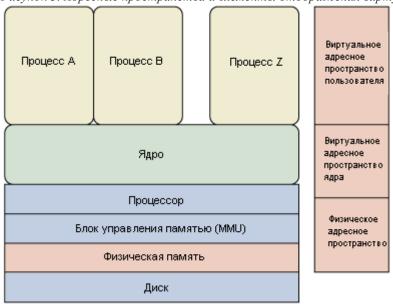


Процессоры без блока управления памятью (ММИ)

Не все процессоры имеют блок управления памятью, поэтому дистрибутив uClinux (версия ОС Linux для микроконтроллеров) поддерживает одноадресное пространство операций. Архитектура без MMU не имеет защиты, обеспечиваемой MMU-блоком, но позволяет ОС Linux работать на процессорах с различными типами архитектур.

Процесс выбора страниц, которые должны быть выгружены на диск, называется *алгоритмом замещения страниц* и может быть реализован по-разному (например, существует алгоритм замещения блока данных с наиболее длительным отсутствием обращений). Этот процесс может начаться в момент обращения к адресу памяти, страница которого не находится в ОЗУ (page fault) (в блоке управления памятью отсутствует ее отображение). рис. 3.

В операционной системе Linux подкачка реализована интересным способом, обладающим рядом полезных свойств. Linux позволяет создавать и использовать несколько разделов подкачки и задавать приоритеты для устройств с различным быстродействием, на которые производится выгрузка данных (например, первоочередным устройством для выгрузки является твердотельный накопитель – SSD-диск, а второстепенным – более медленное устройство). Если SSD-накопителю назначен более высокий приоритет, выгрузка данных будет производиться на него до тех пор, пока на нем не закончится свободное место; лишь после этого страницы памяти будут выгружаться на более медленное устройство с меньшим приоритетом. Рисунок 3. Адресные пространства и элементы отображения виртуальных адресов на физические



Не все страницы памяти могут быть выгружены (например, это может быть код ядра, отвечающий за прерывания, или код управления страничными таблицами и логикой подкачки). Очевидно, что такие страницы никогда не должны выгружаться и поэтому являются закрепленными (pinned), т. е. постоянно находятся в оперативной памяти. В отличие от страниц ядра, которые никогда не выгружаются, страницы адресного пространства пользователя могут быть выгружены, однако их можно закрепить с помощью

функции mlock (или mlockall). Рассмотрим следующую ситуацию: ядро предположило, что переданный пользователем адрес являлся допустимым и доступным, но по какой-либо причине возникло состояние отсутствия страницы в ядре (например, потому, что пользовательская страница была выгружена). В этом случае может наступить состояние паники ядра. АРІ-функция mlock предназначена именно для того, чтобы обеспечивать корректную обработку таких ситуаций.

Для взаимодействия приложений с ядром и ядра с приложениями используются следующие функции:

Формальные параметры

 $void __user * to - Adpec$ назначения находится в пространстве пользователя.

const void * from - Адрес источника находится в пространстве ядра.

unsigned long n - количество копируемых байт.

Контекст

Только пользовательский контекст. Эта функция может переводить процесс в состояние sleep, если включено pagefault.

Описание

Копирует данные из ядра в пространство пользователя. Вызывающий абонент должен проверить указанный блок с помощью access_ok до вызова этой функции.

Функция возвращает количество байт, которые не могут быть скопированы. В случае успешного выполнения будет возвращен 0.

• Функция (User Space Memory Access)

```
unsigned void * to, long __copy_from_user (

const void __user * from, unsigned long n);
```

Формальные параметры

void * to - Адрес назначения находится в пространстве ядра.

```
const void \_user * from - адрес источника находится в пространстве поль зователя.
```

unsigned long n - количество копируемых байт.

Контекст

Только пользовательский контекст. Эта функция может переводить процесс в состояние sleep, если включено pagefault.

Описание

Копирует данные из пространства пользователя в пространство ядра. Вызывающий абонент должен проверить указанный заданный блок с помощью access ok до вызова этой функции.

Функция возвращает количество байт, которые не могут быть скопированы. В случае успешного выполнения будет возвращен 0.

Если какие-то данные не могут быть скопированы, эта функция. Если некоторые данные не могут быть скопированы, эта функция добавит нулевые байты к скопированным данным до требуемого размера.

Альтернативная версия - __copy_from_user_inatomic - может быть вызвана из атомарного контекста и не сможет «спать». В этом случае не скопированные байты * НЕ * будут заполнены нулями. Смотрите fs / filemap.h для объяснения того, почему это необходимо.

Функция

int sprintf(char *str, const char *format, ...);

После успешного возврата эти функция возвращает количество напечатанных символов (исключая нулевой байт, используемый для завершения вывода в строки).

Если обнаружена ошибка вывода, возвращается отрицательное значение.

Строка формата - строка символов. Строка формата состоит из нуля или более директив: обычные символы (не %), которые копируются без изменений в выходной поток; и спецификации преобразования, каждая из которых приводит к получению нуля или более последующих аргументов.

Каждая спецификация преобразования вводится символом % и заканчивается спецификатором преобразования. Между ними может быть (в этом порядке) ноль или более флагов, необязательная минимальная ширина поля, необязательная точность и необязательный модификатор длины.

Так как **sprintf** получает строку произвольной длины, ее вызов может привести к переполнению буфера, что невозможно предотвратить. Обратите внимание, что длина строки определена как локально зависимая и ее трудно спрогнозировать. Используйте вместо них **snprintf**.

Перед использованием надо проверить возможность использования функций в конкретной версии ядра.

Данная функция может не поддерживаться разными версиями и подверсиями ядра Linux.

Задание на лабораторную работу

Написать программу — загружаемый модуль ядра (LKM) — которая поддерживает чтение из пространства пользователя и запись в пространство пользователя из пространства ядра.

После загрузки модуля пользователь должен иметь возможность загружать в него строки с помощью команды echo, а затем считывать их с помощью команды cat.

Функция init (например, init_fortune_module) выделяет пространство для «горшка с печеньем» (cookie pot) используя vmalloc(), а затем очищает его с помощью memset().

```
// устаревшая версия – часто приводится на сайтах
cookie_pot = (char *)vmalloc( MAX_COOKIE_LENGTH );
 if (!cookie_pot)
  ret = -ENOMEM;
 } else
  memset(cookie_pot, 0, MAX_COOKIE_LENGTH);
 proc_entry = create_proc_entry( "fortune", 0644, NULL );//начиная с версии
 //3.10 используется proc create data()
  if (proc_entry == NULL)
   ret = -ENOMEM;
   vfree(cookie_pot);
   printk(KERN_INFO "fortune: Couldn't create proc entry\n");
  } else
{
   cookie\_index = 0;
   next\_fortune = 0;
```

Когда cookie_pot (буфер, англ. Buffer) выделен и пуст, создается proc_dir_entry в корне /proc root, который называется, например, fortune.

Файл cookie_pot представляет собой страницу длиной (4 КБ) и управляется двумя индексами. Первый, cookie_index, определяет, где будет записываться следующий файл cookie. Переменная next fortune

определяет, где следующий файл cookie будет считаться для вывода. Я просто переношу next_fortune в начало, когда все состояния были прочитаны.

Запись нового файла cookie_pot: если буфер для записи не доступен, то возвращается -ENOSPC, который передается пользовательскому процессу. В противном случае ЭТО пространство существует, используется функция copy_from_user() копирования для пользовательского буфера непосредственно в файл cookie pot. Затем файл cookie index (B зависимости увеличивается длины пользовательского буфера) и NULL завершает строку. Наконец, возвращается количество символов, фактически записанных в файл cookie_pot.

Чтение: поскольку объявляемый буфер уже находится в пространстве ядра, можно манипулировать им напрямую и использовать sprintf (может не поддерживаться ядром) или сору_to_user() для записи. Если индекс next_fortune больше, чем cookie_index (следующая позиция для записи), то next_fortune уменьшается до нуля, что зацикливает буфер. После того, как строка будет записана в пользовательский буфер, индекс next_fortune увеличивается на длину последней написанной строки.

Листинг 1. Демонстрация работы «fortune cookie» LKM

[root@plato]# insmod fortune.ko

[root@plato]# echo "Success is an individual proposition. Thomas Watson" > /proc/fortune [root@plato]# echo "If a man does his best, what else is there? Gen. Patton" > /proc/fortune [root@plato]# echo "Cats: All your base are belong to us. Zero Wing" > /proc/fortune [root@plato]# cat /proc/fortune

Success is an individual proposition. Thomas Watson

[root@plato]# cat /proc/fortune

If a man does his best, what else is there? Gen. Patton

[root@plato]#

В программе необходимо создать файл, поддиректорию и символическую ссылку.

При демонстрации работы программы удаленно необходимо:

- Продемонстрировать передачу данных из режима пользователя в режим ядра и из режима ядра в режим пользователя с помощью скриншота.
- Показать в каталоге созданный файл, директорию и поддиректорию.